

Informe científico reproducible

Selección, caracterización y requerimientos para un sistema analítico biomédico

Breast Cancer Wisconsin Diagnostic Dataset

Monica Cueto Tapia

Maestría en Inteligencia Artificial, Machine Learning y Data Science
Universidad Pública de El Alto (UPEA)

7 de julio de 2026

Documento académico preparado como evidencia de un proyecto reproducible de Ciencia de Datos. El informe conserva los análisis, tablas, gráficos e interpretaciones del reporte HTML original, reorganizados en formato de investigación con numeración, referencias cruzadas, índices y anexos.

Sin APIs, sin nube, sin descargas de datasets y sin modelos externos de inteligencia artificial.

Tabla de contenidos

1	Resumen ejecutivo	1
2	Fase 1. Búsqueda, comparación y selección del dataset	1
3	Fase 2. Contexto, problema, objetivo y alcance	5
3.1	Contexto	5
3.2	Problema	6
3.3	Objetivo	6
3.4	Alcance	6
3.5	Beneficiarios	6
3.6	Resultados esperados	6
4	Fase 3. Requerimientos del sistema analítico	13
5	Conclusiones	16
6	Bibliografía	16
A	Anexo A. Diccionario exhaustivo de variables	17
B	Anexo B. Estadística descriptiva completa	20
C	Anexo C. Reproducibilidad	23

Índice de figuras

1	Dashboard ejecutivo del dataset seleccionado	1
2	Flujo metodológico del proyecto	2
3	Matriz comparativa de datasets candidatos	4
4	Perfil multicriterio de selección	5
5	Diagrama de completitud por familia de variable	7
6	Distribución de la variable objetivo	8
7	Variables con mayor separación entre diagnósticos	9
8	Heatmap de correlación entre variables de mayor señal	11
9	Distribuciones comparadas de variables prioritarias	12
10	Boxplots robustos por diagnóstico	12
11	Arquitectura reproducible del proyecto	13
12	Cronograma ejecutivo de la práctica	13

Índice de tablas

1	Comparación técnica resumida de datasets candidatos	2
2	Puntajes normalizados usados para la selección del dataset	3
3	Resumen de calidad del dataset seleccionado	6
4	Tamaños de efecto por variable entre diagnósticos	10
5	Requerimientos funcionales	14
6	Requerimientos no funcionales	15
7	Diccionario exhaustivo de variables	18
8	Estadísticos descriptivos de posición y dispersión	21
9	Asimetría, señal univariada y atípicos IQR	22

1 Resumen ejecutivo

Se evaluaron tres datasets disponibles localmente en scikit-learn. El dataset **Breast Cancer Wisconsin Diagnostic** obtuvo el mayor puntaje ponderado (97.7355/100) al combinar tamaño muestral, riqueza dimensional, completitud, preparación analítica, interpretabilidad e impacto. La selección es apropiada para una práctica de maestría porque permite discutir calidad de datos, separación estadística entre clases, redundancia de variables y requerimientos de un flujo analítico reproducible sin depender de servicios externos.

El conjunto seleccionado contiene 569 observaciones, 30 variables predictoras y 0% de valores faltantes. La evidencia univariada más fuerte aparece en *worst concave points* ($|d|=2.6926$), mientras que el análisis de correlación evidencia redundancia fuerte entre medidas geométricas. El tablero ejecutivo de la Figura 1 sintetiza estos hallazgos.

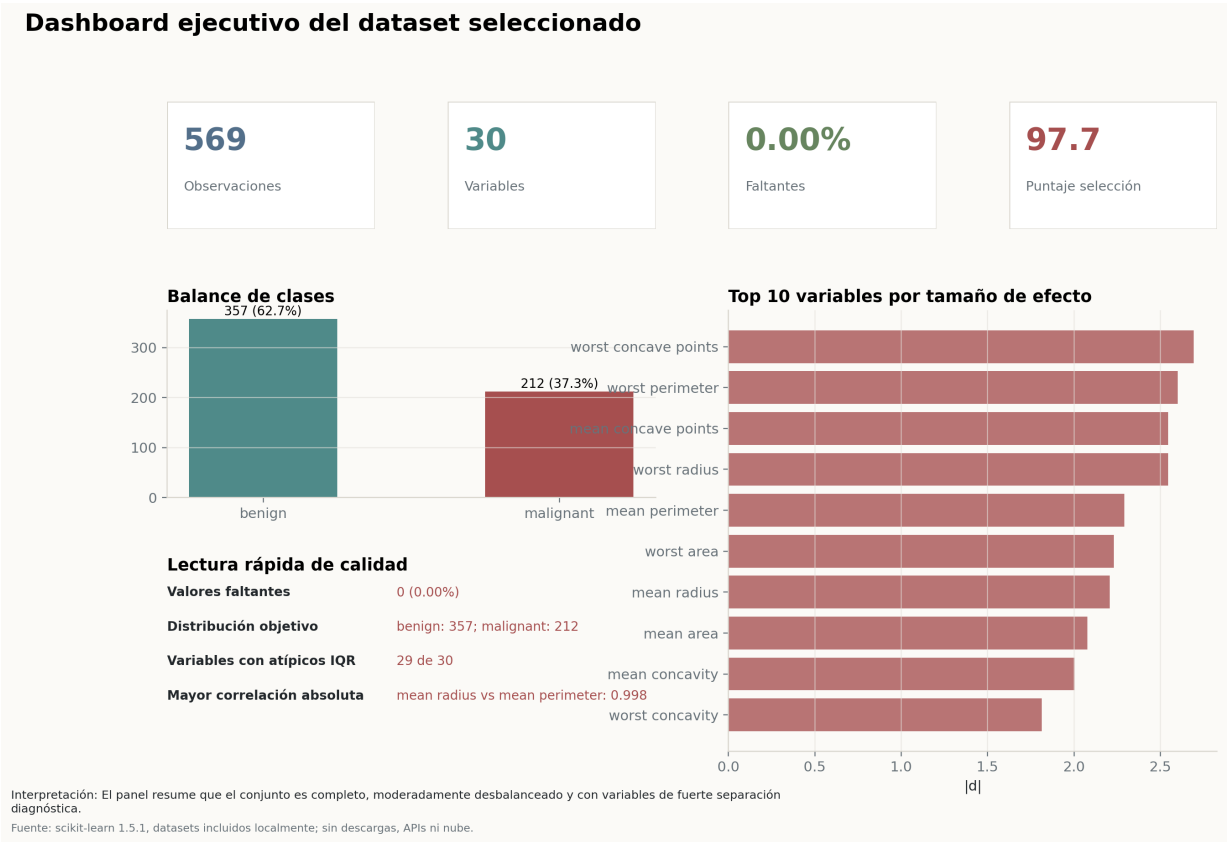




Figura 2: Flujo metodológico del proyecto

Interpretación. El flujo separa selección, análisis y comunicación para que cada conclusión se origine en evidencia verificable.

Tabla 1: Comparación técnica resumida de datasets candidatos

Dataset	Dominio	Tarea	Obs.	Variables	Faltantes (%)	Puntaje total
Breast Cancer Wisconsin Diagnostic	Salud / diagnóstico oncológico	Clasificación binaria	569.0	30.00	0	97.74
Diabetes Progression	Salud / progresión metabólica	Regresión	442.0	10.00	0	83.53
Wine Recognition	Química analítica / enología	Clasificación multiclase	178.0	13.00	0	76.18

Tabla 2: Puntajes normalizados usados para la selección del dataset

Dataset	Tamaño	Dimensión	Compleitud	Prep. analítica	Interpretabilidad	Impacto	Puntaje total
Breast Cancer Wisconsin	100.0	100.0	100.0	94.90	90.00	100.0	97.74
Diagnostic							
Diabetes Progression	88.14	57.73	100.0	100.0	73.00	90.00	83.53
Wine Recognition	55.93	65.83	100.0	96.18	86.00	67.00	76.18




Figura 3: Matriz comparativa de datasets candidatos

Interpretación. El dataset de cáncer de mama domina por tamaño, profundidad de variables, impacto e interpretabilidad; la completitud es equivalente en los tres.




Figura 4: Perfil multicriterio de selección

Interpretación. La decisión no depende de un único criterio: el dataset seleccionado mantiene desempeño alto en seis dimensiones.

La ponderación priorizó evidencia verificable: 25% tamaño muestral, 20% dimensionalidad, 15% completitud, 15% preparación analítica, 15% interpretabilidad y 10% impacto. El dataset seleccionado domina por volumen, número de variables, completitud total y relevancia biomédica. Wine Recognition es técnicamente limpio, pero tiene menor escala e impacto para una discusión socio-técnica. Diabetes Progression posee impacto alto, aunque su objetivo continuo y variables estandarizadas reducen interpretabilidad variable por variable.

3 Fase 2. Contexto, problema, objetivo y alcance

3.1 Contexto

El análisis biomédico basado en imágenes requiere transformar mediciones morfológicas en evidencia interpretable. Este dataset resume características geométricas y de textura de núcleos

celulares obtenidas a partir de aspiración con aguja fina de masas mamarias.

3.2 Problema

Antes de plantear un sistema predictivo, es necesario demostrar que los datos son completos, comprensibles, estadísticamente informativos y gobernables. Sin esa base, cualquier modelo posterior podría amplificar redundancias, sesgos de clase o interpretaciones clínicas débiles.

3.3 Objetivo

Seleccionar y caracterizar un dataset biomédico reproducible, identificar sus variables críticas, evaluar calidad estadística y definir requerimientos de un sistema analítico que pueda sostener futuras fases de modelado con rigor académico.

3.4 Alcance

El alcance cubre selección de dataset, análisis exploratorio, diccionario de datos, visualizaciones editoriales y requerimientos. No incluye entrenamiento de modelos clínicos ni recomendaciones médicas individuales, porque las fases solicitadas no lo exigen y porque se prioriza eficiencia.

3.5 Beneficiarios

Los beneficiarios son estudiantes e investigadores de ciencia de datos, docentes evaluadores, equipos de analítica biomédica y responsables de gobernanza de datos que requieran una base reproducible para decisiones metodológicas.

3.6 Resultados esperados

Se espera una selección defendible, un inventario de variables accionable, evidencia de calidad de datos, detección de señales estadísticas relevantes, visualizaciones publicables y especificación clara de requerimientos para continuidad del proyecto.

Tabla 3: Resumen de calidad del dataset seleccionado

Indicador	Resultado	Interpretación técnica
Observaciones	569.0	Tamaño suficiente para exploración estadística y especificación de requerimientos.
Variables predictoras	30.00	Cobertura morfológica amplia: medias, errores estándar y peores valores.
Variable objetivo	diagnosis	Etiqueta clínica binaria para comparar patrones entre masas benignas y malignas.
Valores faltantes	0 (0.00%)	No se requiere imputación; se preserva trazabilidad.
Filas duplicadas	0	No se detectan registros duplicados exactos en el conjunto final.

Continúa en la siguiente página

Tabla 3: Resumen de calidad del dataset seleccionado (continuación)

Indicador	Resultado	Interpretación técnica
Distribución objetivo	benign: 357; malignant: 212	Existe desbalance moderado, no extremo.
Proporción minoritaria	37.3%	La clase maligna conserva representación analítica suficiente.
Variables con atípicos IQR	29 de 30	Los atípicos deben revisarse como extremos biológicos plausibles, no eliminarse por defecto.
Mayor correlación absoluta	mean radius vs mean perimeter: 0.998	Sugiere redundancia morfológica que debe controlarse en modelado posterior.
Variables con $ d \geq 1$	16.00	La separación univariada es fuerte en varias variables, en especial medidas de concavidad y tamaño.

La Figura 5 confirma completitud total; la Figura 6 muestra un desbalance moderado, no extremo. La señal univariada se observa en la Figura 7 y se complementa con la Tabla 4.



Figura 5: Diagrama de completitud por familia de variable

Interpretación. La completitud uniforme del 100% elimina la necesidad de imputación en esta fase y reduce incertidumbre por datos faltantes.




Figura 6: Distribución de la variable objetivo

Interpretación. La clase benigna es mayoritaria, pero la clase maligna representa más de un tercio del conjunto; el desbalance es manejable para análisis exploratorio.




Figura 7: Variables con mayor separación entre diagnósticos
Interpretación. Las medidas de concavidad, puntos cóncavos y perímetro/área concentran la mayor diferencia estandarizada entre masas malignas y benignas.

Tabla 4: Tamaños de efecto por variable entre diagnósticos

Variable	Media maligno	Media benigno	Diferencia estandarizada (d)	d	Dirección
worst concave points	0.1822	0.0744	2.6926	2.6926	Mayor en maligno
worst perimeter	141.4	87.01	2.5982	2.5982	Mayor en maligno
mean concave points	0.088	0.0257	2.5452	2.5452	Mayor en maligno
worst radius	21.13	13.38	2.5439	2.5439	Mayor en maligno
mean perimeter	115.4	78.08	2.2895	2.2895	Mayor en maligno
worst area	1422.3	558.9	2.2302	2.2302	Mayor en maligno
mean radius	17.46	12.15	2.2055	2.2055	Mayor en maligno
mean area	978.4	462.8	2.0757	2.0757	Mayor en maligno
mean concavity	0.1608	0.0461	2.0033	2.0033	Mayor en maligno
worst concavity	0.4506	0.1662	1.8119	1.8119	Mayor en maligno
mean compactness	0.1452	0.0801	1.5346	1.5346	Mayor en maligno
worst compactness	0.3748	0.1827	1.5126	1.5126	Mayor en maligno
radius error	0.6091	0.2841	1.4217	1.4217	Mayor en maligno
perimeter error	4.3239	2.0003	1.3816	1.3816	Mayor en maligno
area error	72.67	21.14	1.3534	1.3534	Mayor en maligno
worst texture	29.32	23.52	1.0605	1.0605	Mayor en maligno
worst smoothness	0.1448	0.125	0.9596	0.9596	Mayor en maligno
worst symmetry	0.3235	0.2702	0.9453	0.9453	Mayor en maligno
mean texture	21.60	17.91	0.9423	0.9423	Mayor en maligno
concave points error	0.0151	0.0099	0.9228	0.9228	Mayor en maligno
mean smoothness	0.1029	0.0925	0.793	0.793	Mayor en maligno
mean symmetry	0.1929	0.1742	0.723	0.723	Mayor en maligno
worst fractal dimension	0.0915	0.0794	0.7068	0.7068	Mayor en maligno
compactness error	0.0323	0.0214	0.6327	0.6327	Mayor en maligno
concavity error	0.0418	0.026	0.5416	0.5416	Mayor en maligno
fractal dimension error	0.0041	0.0036	0.1615	0.1615	Mayor en maligno
smoothness error	0.0068	0.0072	-0.1387	0.1387	Mayor en benigno
mean fractal dimension	0.0627	0.0629	-0.0265	0.0265	Mayor en benigno
texture error	1.2109	1.2204	-0.0171	0.0171	Mayor en benigno
symmetry error	0.0205	0.0206	-0.0135	0.0135	Mayor en benigno

La Figura 8 evidencia que la señal predictiva convive con multicolinealidad potencial. Las Figuras 9 y 10 muestran los desplazamientos de distribución y mediana entre clases para las variables prioritarias.




Figura 8: Heatmap de correlación entre variables de mayor señal

Interpretación. La señal predictiva convive con redundancia fuerte entre medidas geométricas; esto sugiere cautela con multicolinealidad en fases de modelado.




Figura 9: Distribuciones comparadas de variables prioritarias

Interpretación. Las distribuciones muestran desplazamientos sistemáticos entre clases, especialmente en variables de borde y concavidad.




Figura 10: Boxplots robustos por diagnóstico

Interpretación. La escala robusta permite comparar variables con unidades diferentes y evidencia medianas más altas en malignidad para variables clave.

4 Fase 3. Requerimientos del sistema analítico

Los requerimientos se formulan para un sistema de análisis reproducible, no para un producto clínico operativo. La prioridad se asigna según riesgo metodológico, trazabilidad y valor para decisiones académicas posteriores. La arquitectura propuesta se observa en la Figura 11 y el cronograma ejecutivo en la Figura 12.




Figura 11: Arquitectura reproducible del proyecto

Interpretación. La arquitectura mantiene una sola ruta de datos y separa artefactos finales por función, evitando duplicación y procesamiento innecesario.




Figura 12: Cronograma ejecutivo de la práctica

Interpretación. El cronograma prioriza selección y comprensión de datos antes de cualquier modelado, consistente con una práctica de formulación analítica.

Tabla 5: Requerimientos funcionales

ID	Requerimiento funcional	Categoría	Prioridad	Justificación	Impacto
RF-01	Cargar el dataset seleccionado desde una fuente local versionada.	Ingesta	Alta	Evita dependencias externas y garantiza reproducción en entornos académicos.	Permite reconstruir el análisis sin internet ni APIs.
RF-02	Validar estructura, número de variables, tipos y variable objetivo.	Calidad de datos	Alta	Previene análisis sobre columnas corruptas o incompatibles.	Reduce riesgo de conclusiones no trazables.
RF-03	Calcular métricas de completitud, duplicados y balance del objetivo.	Calidad de datos	Alta	La confiabilidad del diagnóstico depende de ausencia de sesgos de captura.	Define si se requiere imputación, depuración o estratificación.
RF-04	Generar comparación cuantitativa entre tres datasets candidatos.	Selección analítica	Alta	La selección debe sustentarse en criterios medibles y no en preferencia subjetiva.	Justifica el dataset ante evaluación académica.
RF-05	Construir diccionario exhaustivo de variables con rango, unidad e importancia.	Documentación	Alta	La interpretación clínica necesita semántica clara por variable.	Mejora auditabilidad y transferencia del proyecto.
RF-06	Calcular estadísticos descriptivos robustos por variable.	EDA	Alta	Percentiles, asimetría y atípicos revelan la estructura real de los datos.	Soporta decisiones de transformación y modelado futuro.
RF-07	Cuantificar separación entre clases mediante tamaño de efecto.	Análisis estadístico	Alta	El tamaño de efecto aporta evidencia interpretable sin entrenar modelos innecesarios.	Prioriza variables relevantes para diagnóstico.
RF-08	Identificar correlaciones altas entre variables predictoras.	Análisis estadístico	Media	La redundancia puede afectar interpretabilidad y estabilidad de modelos futuros.	Informa reducción dimensional o regularización posterior.
RF-09	Exportar tablas finales en formato reutilizable.	Entregables	Media	Las tablas deben poder revisarse, auditarse o integrarse en anexos.	Facilita evaluación y continuidad del trabajo.
RF-10	Compilar un reporte HTML editorial con figuras, tablas e interpretación.	Reporte	Alta	El entregable final debe comunicar evidencia, no solo producir archivos.	Aumenta claridad, profesionalismo y presentabilidad.

Tabla 6: Requerimientos no funcionales

ID	Requerimiento no funcional	Prioridad	Justificación	Impacto
RNF-01	Reproducibilidad	Alta	El flujo debe ejecutarse con un único script local y resultados deterministas.	Permite validar el trabajo en cualquier revisión académica.
RNF-02	Eficiencia computacional	Alta	Solo se cargan datasets livianos y se evita entrenamiento innecesario.	Minimiza tiempo, memoria y consumo de recursos.
RNF-03	Independencia de red	Alta	No se usan descargas, APIs, nube ni modelos externos.	El proyecto cumple restricciones y protege continuidad operativa.
RNF-04	Trazabilidad	Alta	Cada figura y tabla declara fuente e interpretación.	Facilita auditoría de evidencia y defensa metodológica.
RNF-05	Interpretabilidad	Alta	Las métricas se basan en estadística descriptiva y tamaño de efecto.	Evita cajas negras en fases tempranas del proyecto.
RNF-06	Mantenibilidad	Media	El código separa carga, métricas, visualización y reporte.	Permite extender el análisis sin rehacer la base.
RNF-07	Portabilidad	Media	Usa únicamente Python, Pandas, NumPy, Matplotlib y scikit-learn.	Reduce fricción de instalación y dependencia de librerías pesadas.
RNF-08	Calidad visual	Alta	La salida debe usar paleta sobria, espacio en blanco y jerarquía editorial.	Mejora comunicación de hallazgos a audiencias técnicas y ejecutivas.
RNF-09	Robustez	Media	Las validaciones deben fallar de forma explícita ante cambios de estructura.	Evita reportes silenciosamente inconsistentes.
RNF-10	Gobernanza ética	Alta	El análisis evita inferencias clínicas individualizadas y trata el dataset como material académico.	Reduce riesgo de uso indebido en decisiones médicas reales.

5 Conclusiones

- La selección del dataset es cuantitativamente defendible: Breast Cancer Wisconsin Diagnostic alcanza 97.7355/100 y supera a los candidatos por balance entre escala, dimensionalidad, interpretabilidad e impacto.
- La completitud del 100% evita imputación en esta fase; por tanto, las diferencias observadas entre clases no están condicionadas por estrategias de reemplazo de datos faltantes.
- La clase maligna conserva representación analítica suficiente para exploración, aunque un modelado posterior debería controlar el desbalance con particiones estratificadas.
- La presencia de múltiples variables con $|d| \geq 1$ indica separación estadística fuerte; no obstante, la correlación alta entre medidas geométricas confirma información redundante.
- La fase de requerimientos debe priorizar reproducibilidad, trazabilidad, independencia de red y comunicación visual, porque esos atributos hacen defendible el proyecto en un contexto de maestría.

6 Bibliografía

Bibliografía

- [1] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [2] Street, W. N., Wolberg, W. H., & Mangasarian, O. L. (1993). *Nuclear feature extraction for breast tumor diagnosis*. IS&T/SPIE International Symposium on Electronic Imaging.
- [3] Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1995). *Breast cancer diagnosis and prognosis via linear programming*. Operations Research, 43(4), 570–577.

A Anexo A. Diccionario exhaustivo de variables

La Tabla 7 reproduce el diccionario completo de variables del proyecto, con tipo, descripción, rango observado, unidad, importancia, posibles valores atípicos y observaciones técnicas.

Tabla 7: Diccionario exhaustivo de variables

Nombre	Tipo	Descripción	Rango / valores	Unidad	Importancia	Posibles valores atípicos	Obs.
diagnosis	categórica nominal	Variable objetivo: diagnóstico histopatológico codificado como maligno o benigno.	malignant, benign	categoría clínica	Crítica	No aplica; se valida consistencia de etiquetas.	Es la variable de referencia para segmentar el análisis estadístico.
mean radius	numérica continua	Media de distancia media desde el centro hasta puntos del perímetro celular.	6.981 a 28.11	unidades de imagen	Muy alta	14 casos (2.5%) fuera de [5.58, 21.9] por regla IQR.	mayor en maligno; $ d =2.21$; asimetría moderada.
mean texture	numérica continua	Media de variabilidad de la intensidad de gris en la imagen.	9.71 a 39.28	desviación estándar de niveles de gris	Media	7 casos (1.2%) fuera de [7.73, 30.2] por regla IQR.	mayor en maligno; $ d =0.94$; asimetría moderada.
mean perimeter	numérica continua	Media de longitud del contorno de la masa celular.	43.79 a 188.5	unidades de imagen	Muy alta	13 casos (2.3%) fuera de [31.8, 147] por regla IQR.	mayor en maligno; $ d =2.29$; asimetría moderada.
mean area	numérica continua	Media de superficie proyectada de la masa celular.	143.5 a 2501	unidades cuadradas de imagen	Muy alta	25 casos (4.4%) fuera de [-123, 1.33e+03] por regla IQR.	mayor en maligno; $ d =2.08$; asimetría marcada.
mean smoothness	numérica continua	Media de variación local de longitudes de radio.	0.05263 a 0.1634	índice adimensional	Media	6 casos (1.1%) fuera de [0.058, 0.134] por regla IQR.	mayor en maligno; $ d =0.79$; distribución relativamente estable.
mean compactness	numérica continua	Media de relación de compacidad calculada como perímetro al cuadrado sobre área menos uno.	0.01938 a 0.3454	índice adimensional	Alta	16 casos (2.8%) fuera de [-0.0333, 0.229] por regla IQR.	mayor en maligno; $ d =1.53$; asimetría marcada.
mean concavity	numérica continua	Media de severidad de porciones cóncavas del contorno.	0 a 0.4268	índice adimensional	Muy alta	18 casos (3.2%) fuera de [-0.122, 0.282] por regla IQR.	mayor en maligno; $ d =2.00$; asimetría marcada.
mean concave points	numérica continua	Media de cantidad relativa de puntos cóncavos del contorno.	0 a 0.2012	índice adimensional	Muy alta	10 casos (1.8%) fuera de [-0.0602, 0.155] por regla IQR.	mayor en maligno; $ d =2.55$; asimetría marcada.
mean symmetry	numérica continua	Media de grado de simetría de la estructura celular.	0.106 a 0.304	índice adimensional	Media	15 casos (2.6%) fuera de [0.111, 0.246] por regla IQR.	mayor en maligno; $ d =0.72$; asimetría moderada.
mean fractal dimension	numérica continua	Media de aproximación de complejidad del contorno celular.	0.04996 a 0.09744	índice adimensional	Exploratoria	15 casos (2.6%) fuera de [0.0451, 0.0787] por regla IQR.	mayor en benigno; $ d =0.03$; asimetría marcada.
radius error	numérica continua	Error estándar de distancia media desde el centro hasta puntos del perímetro celular.	0.1115 a 2.873	unidades de imagen	Alta	38 casos (6.7%) fuera de [-0.137, 0.849] por regla IQR.	mayor en maligno; $ d =1.42$; asimetría marcada.
texture error	numérica continua	Error estándar de variabilidad de la intensidad de gris en la imagen.	0.3602 a 4.885	desviación estándar de niveles de gris	Exploratoria	20 casos (3.5%) fuera de [-0.126, 2.43] por regla IQR.	mayor en benigno; $ d =0.02$; asimetría marcada.
perimeter error	numérica continua	Error estándar de longitud del contorno de la masa celular.	0.757 a 21.98	unidades de imagen	Alta	38 casos (6.7%) fuera de [-1.02, 5.98] por regla IQR.	mayor en maligno; $ d =1.38$; asimetría marcada.
area error	numérica continua	Error estándar de superficie proyectada de la masa celular.	6.802 a 542.2	unidades cuadradas de imagen	Alta	65 casos (11.4%) fuera de [-23.2, 86.2] por regla IQR.	mayor en maligno; $ d =1.35$; asimetría marcada.
smoothness error	numérica continua	Error estándar de variación local de longitudes de radio.	0.001713 a 0.03113	índice adimensional	Exploratoria	30 casos (5.3%) fuera de [0.000703, 0.0126] por regla IQR.	mayor en benigno; $ d =0.14$; asimetría marcada.
compactness error	numérica continua	Error estándar de relación de compacidad calculada como perímetro al cuadrado sobre área menos uno.	0.002252 a 0.1354	índice adimensional	Exploratoria	28 casos (4.9%) fuera de [-0.016, 0.0615] por regla IQR.	mayor en maligno; $ d =0.63$; asimetría marcada.
concavity error	numérica continua	Error estándar de severidad de porciones cóncavas del contorno.	0 a 0.396	índice adimensional	Exploratoria	22 casos (3.9%) fuera de [-0.0253, 0.0825] por regla IQR.	mayor en maligno; $ d =0.54$; asimetría marcada.
concave points error	numérica continua	Error estándar de cantidad relativa de puntos cóncavos del contorno.	0 a 0.05279	índice adimensional	Media	19 casos (3.3%) fuera de [-0.00297, 0.0253] por regla IQR.	mayor en maligno; $ d =0.92$; asimetría marcada.
symmetry error	numérica continua	Error estándar de grado de simetría de la estructura celular.	0.007882 a 0.07895	índice adimensional	Exploratoria	27 casos (4.7%) fuera de [0.00268, 0.036] por regla IQR.	mayor en benigno; $ d =0.01$; asimetría marcada.
fractal dimension error	numérica continua	Error estándar de aproximación de complejidad del contorno celular.	0.0008948 a 0.02984	índice adimensional	Exploratoria	28 casos (4.9%) fuera de [-0.00122, 0.00802] por regla IQR.	mayor en maligno; $ d =0.16$; asimetría marcada.
worst radius	numérica continua	Peor valor de distancia media desde el centro hasta puntos del perímetro celular.	7.93 a 36.04	unidades de imagen	Muy alta	17 casos (3.0%) fuera de [4.34, 27.5] por regla IQR.	mayor en maligno; $ d =2.54$; asimetría marcada.
worst texture	numérica continua	Peor valor de variabilidad de la intensidad de gris en la imagen.	12.02 a 49.54	desviación estándar de niveles de gris	Media	5 casos (0.9%) fuera de [8.12, 42.7] por regla IQR.	mayor en maligno; $ d =1.06$; distribución relativamente estable.
worst perimeter	numérica continua	Peor valor de longitud del contorno de la masa celular.	50.41 a 251.2	unidades de imagen	Muy alta	15 casos (2.6%) fuera de [22.2, 187] por regla IQR.	mayor en maligno; $ d =2.60$; asimetría marcada.
worst area	numérica continua	Peor valor de superficie proyectada de la masa celular.	185.2 a 4254	unidades cuadradas de imagen	Muy alta	35 casos (6.2%) fuera de [-338, 1.94e+03] por regla IQR.	mayor en maligno; $ d =2.23$; asimetría marcada.

Continúa en la siguiente página

Tabla 7: Diccionario exhaustivo de variables (continuación)

Nombre	Tipo	Descripción	Rango / valores	Unidad	Importancia	Posibles valores atípicos	Obs.
worst smoothness	numérica continua	Peor valor de variación local de longitudes de radio.	0.07117 a 0.2226	índice adimensional	Media	7 casos (1.2%) fuera de [0.0725, 0.19] por regla IQR.	mayor en maligno; $ d =0.96$; distribución relativamente estable.
worst compactness	numérica continua	Peor valor de relación de compacidad calculada como perímetro al cuadrado sobre área menos uno.	0.02729 a 1.058	índice adimensional	Alta	16 casos (2.8%) fuera de [-0.141, 0.627] por regla IQR.	mayor en maligno; $ d =1.51$; asimetría marcada.
worst concavity	numérica continua	Peor valor de severidad de porciones cóncavas del contorno.	0 a 1.252	índice adimensional	Alta	12 casos (2.1%) fuera de [-0.288, 0.786] por regla IQR.	mayor en maligno; $ d =1.81$; asimetría marcada.
worst concave points	numérica continua	Peor valor de cantidad relativa de puntos cóncavos del contorno.	0 a 0.291	índice adimensional	Muy alta	0 casos (0.0%) fuera de [-0.0798, 0.306] por regla IQR.	mayor en maligno; $ d =2.69$; distribución relativamente estable.
worst symmetry	numérica continua	Peor valor de grado de simetría de la estructura celular.	0.1565 a 0.6638	índice adimensional	Media	23 casos (4.0%) fuera de [0.149, 0.419] por regla IQR.	mayor en maligno; $ d =0.95$; asimetría marcada.
worst fractal dimension	numérica continua	Peor valor de aproximación de complejidad del contorno celular.	0.05504 a 0.2075	índice adimensional	Media	24 casos (4.2%) fuera de [0.0405, 0.123] por regla IQR.	mayor en maligno; $ d =0.71$; asimetría marcada.

B Anexo B. Estadística descriptiva completa

Las Tablas 8 y 9 presentan los estadísticos de posición, dispersión, asimetría, atípicos IQR y señal univariada conservados desde el reporte HTML.

Tabla 8: Estadísticos descriptivos de posición y dispersión

Variable	n	Media	Dev. estándar	Mínimo	P1	P25	Mediana	P75	P99	Máximo
mean radius	569.0	14.13	3.524	6.981	8.4584	11.70	13.37	15.78	24.37	28.11
mean texture	569.0	19.29	4.301	9.71	10.93	16.17	18.84	21.80	30.65	39.28
mean perimeter	569.0	91.97	24.30	43.79	53.83	75.17	86.24	104.1	165.7	188.5
mean area	569.0	654.9	351.9	143.5	215.7	420.3	551.1	782.7	1786.6	2501.0
mean smoothness	569.0	0.0964	0.0141	0.0526	0.0687	0.0864	0.0959	0.1053	0.1329	0.1634
mean compactness	569.0	0.1043	0.0528	0.0194	0.0334	0.0649	0.0926	0.1304	0.2772	0.3454
mean concavity	569.0	0.0888	0.0797	0	0	0.0296	0.0615	0.1307	0.3517	0.4268
mean concave points	569.0	0.0489	0.0388	0	0	0.0203	0.0335	0.074	0.1642	0.2012
mean symmetry	569.0	0.1812	0.0274	0.106	0.1295	0.1619	0.1792	0.1957	0.2596	0.304
mean fractal dimension	569.0	0.0628	0.0071	0.05	0.0515	0.0577	0.0615	0.0661	0.0854	0.0974
radius error	569.0	0.4052	0.2773	0.1115	0.1197	0.2324	0.3242	0.4789	1.2913	2.873
texture error	569.0	1.2169	0.5516	0.3602	0.4105	0.8339	1.108	1.474	2.9154	4.885
perimeter error	569.0	2.8661	2.0219	0.757	0.9532	1.606	2.287	3.357	9.69	21.98
area error	569.0	40.34	45.49	6.802	8.5144	17.85	24.53	45.19	177.7	542.2
smoothness error	569.0	0.007	0.003	0.0017	0.0031	0.0052	0.0064	0.0081	0.0173	0.0311
compactness error	569.0	0.0255	0.0179	0.0023	0.0047	0.0131	0.0204	0.0324	0.0899	0.1354
concavity error	569.0	0.0319	0.0302	0	0	0.0151	0.0259	0.042	0.1223	0.396
concave points error	569.0	0.0118	0.0062	0	0	0.0076	0.0109	0.0147	0.0312	0.0528
symmetry error	569.0	0.0205	0.0083	0.0079	0.0105	0.0152	0.0187	0.0235	0.0522	0.079
fractal dimension error	569.0	0.0038	0.0026	0.0009	0.0011	0.0022	0.0032	0.0046	0.0126	0.0298
worst radius	569.0	16.27	4.8332	7.93	9.2076	13.01	14.97	18.79	30.76	36.04
worst texture	569.0	25.68	6.1463	12.02	15.20	21.08	25.41	29.72	41.80	49.54
worst perimeter	569.0	107.3	33.60	50.41	58.27	84.11	97.66	125.4	208.3	251.2
worst area	569.0	880.6	569.4	185.2	256.2	515.3	686.5	1084.0	2918.2	4254.0
worst smoothness	569.0	0.1324	0.0228	0.0712	0.0879	0.1166	0.1313	0.146	0.1889	0.2226
worst compactness	569.0	0.2543	0.1573	0.0273	0.0501	0.1472	0.2119	0.3391	0.7786	1.058
worst concavity	569.0	0.2722	0.2086	0	0	0.1145	0.2267	0.3829	0.9024	1.252
worst concave points	569.0	0.1146	0.0657	0	0	0.0649	0.0999	0.1614	0.2692	0.291
worst symmetry	569.0	0.2901	0.0619	0.1565	0.176	0.2504	0.2822	0.3179	0.4869	0.6638
worst fractal dimension	569.0	0.0839	0.0181	0.055	0.0586	0.0715	0.08	0.0921	0.1406	0.2075

Tabla 9: Asimetría, señal univariada y atípicos IQR

Variable	Asimetría	d	Dirección	Atípicos IQR	Atípicos IQR (%)
mean radius	0.9424	2.2055	Mayor en maligno	14.00	2.4605
mean texture	0.6504	0.9423	Mayor en maligno	7	1.2302
mean perimeter	0.9907	2.2895	Mayor en maligno	13.00	2.2847
mean area	1.6457	2.0757	Mayor en maligno	25.00	4.3937
mean smoothness	0.4563	0.793	Mayor en maligno	6	1.0545
mean compactness	1.1901	1.5346	Mayor en maligno	16.00	2.812
mean concavity	1.4012	2.0033	Mayor en maligno	18.00	3.1634
mean concave points	1.1712	2.5452	Mayor en maligno	10.00	1.7575
mean symmetry	0.7256	0.723	Mayor en maligno	15.00	2.6362
mean fractal dimension	1.3045	0.0265	Mayor en benigno	15.00	2.6362
radius error	3.0886	1.4217	Mayor en maligno	38.00	6.6784
texture error	1.6464	0.0171	Mayor en benigno	20.00	3.5149
perimeter error	3.4436	1.3816	Mayor en maligno	38.00	6.6784
area error	5.4472	1.3534	Mayor en maligno	65.00	11.42
smoothness error	2.3145	0.1387	Mayor en benigno	30.00	5.2724
compactness error	1.9022	0.6327	Mayor en maligno	28.00	4.9209
concavity error	5.1105	0.5416	Mayor en maligno	22.00	3.8664
concave points error	1.4447	0.9228	Mayor en maligno	19.00	3.3392
symmetry error	2.1951	0.0135	Mayor en benigno	27.00	4.7452
fractal dimension error	3.924	0.1615	Mayor en maligno	28.00	4.9209
worst radius	1.1031	2.5439	Mayor en maligno	17.00	2.9877
worst texture	0.4983	1.0605	Mayor en maligno	5	0.8787
worst perimeter	1.1282	2.5982	Mayor en maligno	15.00	2.6362
worst area	1.8594	2.2302	Mayor en maligno	35.00	6.1511
worst smoothness	0.4154	0.9596	Mayor en maligno	7	1.2302
worst compactness	1.4736	1.5126	Mayor en maligno	16.00	2.812
worst concavity	1.1502	1.8119	Mayor en maligno	12.00	2.109
worst concave points	0.4926	2.6926	Mayor en maligno	0	0
worst symmetry	1.4339	0.9453	Mayor en maligno	23.00	4.0422
worst fractal dimension	1.6626	0.7068	Mayor en maligno	24.00	4.2179

C Anexo C. Reproducibilidad

El proyecto se reproduce desde la raíz del repositorio con:

```
python src/build_project.py
```

El PDF se compone a partir de los artefactos finales con:

```
python src/build_pdf_report.py
```

Durante la generación de este documento no se recalcularon estadísticas ni se regeneraron gráficos analíticos. Solo se transformaron los artefactos existentes en una versión académica en PDF.